CONCEITUAIS

1. **Descreva as hipóteses nulas às quais os valores-p apresentados na Tabela 3.4 correspondem. Explique quais conclusões podem ser tiradas com base nesses valores-p. Sua explicação deve ser formulada em termos de vendas, TV, rádio e jornal, em vez de em termos dos coeficientes do modelo linear.**

	Coeficiente	Desvio Padrão	t-estatística	p-valor
Intercepto	2.939	0.3119	9.42	<0.0001
TV	0.046	0.0014	32.81	<0.0001
Rádio	0.189	0.0086	21.89	<0.0001
Jornal	-0.001	0.0059	-0.18	0.8599

Estamos interressados em validar se vendas está relacionado em investimentos em marketing. Olhando para um modelo linear simples, temos algumas obsevações

Intercepto - Mesmo sem investir em nenhuma mídia, existe um valor médio de vendas de 2.939

TV - Apresenta p-value baixo, então no cenário em que o coeficiente de TV seja 0 é muito improvável ele não ter significância. Logo temos forte indícios que existe uma relação entre vendas e TV.

Rádio - Apresenta p-value baixo, então no cenário em que o coeficiente de Rádio seja 0 é muito improvável ele não ter significância. Logo temos forte indícios que existe uma relação entre vendas e Rádio.

Jornal - Apresenta p-value alto, então temos forte indícios que a hipótese nula pode ser possível. Neste caso, qualquer efeito de Jornal sobre vendas pode ser explicado pelo acaso.

2. **Explique cuidadosamente as diferenças entre os métodos de classificação KNN e regressão KNN.**

O modelo KNN é não-paramétrico, ou seja, não utiliza uma equação pré-definida para modelar os dados. Ele se baseia diretamente nos exemplos do conjunto de treinamento, e por isso seu comportamento depende bastante da escolha do valor de K.

Na classificação, o algoritmo busca os K vizinhos mais próximos da amostra e atribui a ela a classe mais frequente entre esses vizinhos.

Na regressão, a lógica é semelhante, mas em vez de escolher a classe majoritária, calcula-se a média (que pode ser ponderada ou não) dos valores de saída dos K vizinhos mais próximos, e esse valor é usado como previsão.

3. **Suponha que temos um conjunto de dados com cinco preditores:**
   - **X1 = GPA (média de notas)**
   - **X2 = IQ (quociente de inteligência)**
   - **X3 = Nível (1 para Faculdade e 0 para Ensino Médio)**
   - **X4 = Interação entre GPA e IQ**
   - **X5 = Interação entre GPA e Nível**

   A variável resposta é o salário inicial após a graduação (em milhares de dólares). Suponha que usamos mínimos quadrados para ajustar o modelo e obtemos: β0 = 50, β1 = 20, β2 = 0.07, β3 = 35, β4 = 0.01, β5 = -10.

   (a) Qual resposta está correta, e por quê?

   i. Para um valor fixo de IQ e GPA, graduados do ensino médio ganham mais, em média, do que graduados da faculdade.

   ii. Para um valor fixo de IQ e GPA, graduados da faculdade ganham mais, em média, do que graduados do ensino médio.

   iii. Para um valor fixo de IQ e GPA, graduados do ensino médio ganham mais, em média, do que graduados da faculdade, desde que o GPA seja suficientemente alto.

   iv. Para um valor fixo de IQ e GPA, graduados da faculdade ganham mais, em média, do que graduados do ensino médio, desde que o GPA seja suficientemente alto.

O coeficiente de X3 (Nível) é positivo (35), o que indica que, para valores fixos de IQ e GPA, formados em faculdade tendem a ganhar mais do que apenas ensino médio.

- O coeficiente de interação X5 (GPA × Nível) é negativo (-10), mostrando que, conforme o GPA aumenta, a vantagem da faculdade diminui. Para GPA suficientemente alto, o ensino médio pode até superar a faculdade.

- Além disso, vale notar que o coeficiente de **X2 (IQ)** é pequeno (0.07). Sem conhecer o desvio padrão, não sabemos se esse efeito é

estatisticamente significativo ou se pode ser apenas ruído. Isso reforça a ideia de que não basta olhar o valor do coeficiente: é preciso considerar também a variabilidade e os testes de significância.

Logo a alternativa iii é a mais plausível

(b) Calcule o salário previsto para um graduado da faculdade com IQ = 110 e GPA = 4,0, e compare com o salário previsto para um graduado do ensino médio com os mesmos valores de IQ e GPA. Mostre se, nesse caso, a vantagem da faculdade ainda existe ou se o ensino médio passa a ter salário maior.

$$Y = \beta_0 + \beta_1 \cdot GPA + \beta_2 \cdot IQ + \beta_3 \cdot Nível + \beta_4 \cdot (GPA \cdot IQ) + \beta_5 \cdot (GPA \cdot Nível)$$

$$Y_{fa} = 50 + 20 \cdot GPA + 0.07 \cdot 110 + 35 \cdot 1 + 0.01 \cdot GPA \cdot 110 - 10 \cdot GPA \cdot 1$$

$$Y_{fa} = 92.7 + 11.1 \cdot GPA \quad \text{(Faculdade)}$$

$$Y_{\text{em}} = 50 + 20 \cdot GPA + 7.7 + 0 + 1.1 \cdot GPA + 0$$

$$Y_{\text{em}} = 57.7 + 21.1 \cdot GPA \quad \text{(Ensino Médio)}$$

<u>Caso tenhamos duas pessoas com mesmo IQ, mas um tem faculdade e outro não, em que ponto GPA se torna mais rentável para pessoas sem faculdade.</u>

$$Y_{\text{fa}} = Y_{em}$$

$$92.7 + 11.1 \cdot GPA = 57.7 + 21.1 \cdot GPA$$

$$35 = 10 \cdot GPA$$

$$GPA = 3.5$$

- Se GPA<3.5, a diferença é positiva → faculdade ganha mais.
- Se GPA=3.5, salários iguais.
- Se GPA>3.5, a diferença é negativa → ensino médio ganha mais.

<u>Para o caso em que temos GPA 4</u>

$$Y_{fa} = 92.7 + 11.1 \cdot 4 = 137.1, \qquad Y_{em} = 57.7 + 21.1 \cdot 4 = 142.1$$

(c) Verdadeiro ou falso: Como o coeficiente para o termo de interação GPA/IQ é muito pequeno, há pouca evidência de um efeito de interação. Justifique sua resposta.

Indica um efeito pequeno em magnitude. Porém, o tamanho do coeficiente sozinho não basta para concluir se há ou não interação. É necessário verificar também o p-value:

- Se o p-value for baixo, mesmo um coeficiente pequeno é estatisticamente significativo, ou seja, há evidência de interação.
- Se o p-value for alto, não rejeitamos a hipótese nula e não há evidência de interação.

4. Eu coleto um conjunto de dados (n = 100 observações) contendo um único preditor e uma resposta quantitativa. Em seguida, ajusto um modelo de regressão linear aos dados, bem como uma regressão cúbica separada, isto é:

Y = β0 + β1X + β2X2 + β3X3 + ε

(a) Suponha que a relação verdadeira entre X e Y seja linear, isto é:

Y = β0 + β1X + ε

Considere a soma dos quadrados dos resíduos (RSS) no treinamento para a regressão linear e também para a regressão cúbica. Esperaríamos que uma fosse menor que a outra, esperaríamos que fossem iguais, ou não há informação suficiente para dizer? Justifique sua resposta.

Esperaríamos que fosse iguais, pois para o modelo de regressão cúbico, os coeficientes seriam aproximadamente nulos, ou seja, os p-valores seriam altos.

(b) Responda ao item (a) usando o RSS de teste em vez do RSS de treinamento.

Neste caso o RSS de treinamento para o modelo cúbico seria ligeiramente maior ou igual ao do modelo linear simples, pois ele é mais flexível e pode capturar alguns desvios de linearidade das amostras (overfitting), porém como vimos termos extras não possuem efeito real, apenas

adicionando variância ao modelo sem reduzir viés. Então esta pequena diferença seria extritamente da complexidade extra desnecessária.

(c) Suponha que a relação verdadeira entre X e Y não seja linear, mas não sabemos o quão distante ela está de ser linear. Considere o RSS de treinamento para a regressão linear e também para a regressão cúbica. Esperaríamos que uma fosse menor que a outra, esperaríamos que fossem iguais, ou não há informação suficiente para dizer? Justifique sua resposta.

Neste caso o RSS de treinamento para o modelo cúbico seria ligeiramente menor ou igual ao do modelo linear simples, pois ele é mais flexível e consegue capturar parte dos desvios da linearidade. Assim, reduz o viés do modelo linear.

(d) Responda ao item (c) usando o RSS de teste em vez do RSS de treinamento.

Neste caso o RSS de teste para o modelo cúbico pode ser maior ou igual ao do modelo linear, dependendo de quão distante a relação verdadeira está da linearidade. Se o desvio for pequeno, o cúbico tende a sofrer com variância extra e overfitting, resultando em pior desempenho no teste. Se o desvio for grande, o cúbico pode capturar melhor a estrutura e ter RSS de teste menor. Ou seja, agora temos o risco de underfitting no modelo linear e o trade-off entre viés e variância no modelo cúbico.

5. **Considere os valores ajustados que resultam da realização de regressão linear sem intercepto. Nesse cenário, o i-ésimo valor ajustado assume a forma**

$$\hat{y}_i = x_i\hat{\beta}$$

Onde

$$\hat{\beta} = \frac{\sum_{j=1}^{n} x_j y_j}{\sum_{j=1}^{n} x_j^2}$$

Mostre que podemos escrever

$$\hat{y}_i = \sum_{j=1}^{n} a_j y_j$$

O que é a_j?

Nota: Interpretamos este resultado dizendo que os valores ajustados da regressão linear são combinações lineares dos valores da resposta.

Substituindo $\hat{\beta}$ em $\hat{y}_i$, temos:

$$\hat{y}_i = \boldsymbol{x_i} \cdot \frac{\sum_{j=1}^{n} \boldsymbol{x_j y_j}}{\sum_{j=1}^{n} \boldsymbol{x_j^2}}$$

$$\hat{y}_i = \frac{\boldsymbol{x_i}}{\sum_{j=1}^{n} \boldsymbol{x_j^2}} \sum_{j=1}^{n} \boldsymbol{x_j y_j}$$

$$\hat{y}_i = \sum_{j=1}^{n} \left(\frac{\boldsymbol{x_i x_j}}{\sum_{k=1}^{n} \boldsymbol{x_k^2}} \right) \boldsymbol{y_j}$$

Logo podemos escrever:

$$\hat{y}_i = \sum_{j=1}^{n} a_j y_j$$

onde

$$\boldsymbol{a}_{\mathrm{j}} = \frac{\boldsymbol{x_i x}_{\mathrm{j}}}{\sum_{k=1}^{n} \boldsymbol{x_k^2}}$$

Logo a_j representa ao peso associado ao valor observado y_j, desta forma, cada valor ajustado $\hat{y}_i$ é uma combinação linear dos valores observados, onde os pesos são determinados exclusivamente pelos valores de x.

Em resumo: Todo valor que prevemos no modelo, é dependente de todas as amostras de treinamento, com pesos diversos, ditados pelas variáveis do modelo.

6. **Usando a equação (3.4), mostre que, no caso da regressão linear simples, a reta de mínimos quadrados sempre passa pelo ponto $(\bar{x}, \bar{y})$**

$$\widehat{\beta_1} = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}$$

$$\widehat{\beta_0} = \bar{y} - \widehat{\beta_1} \bar{x}$$

Sabemos que a equação de uma regressão linear simples é a seguinte

$$\hat{y} = \widehat{\beta_0} + \widehat{\beta_1} x$$

Se queremos verificar se a reta passa pelos pontos médios podemos verificar:

$$\hat{y}(\bar{x}) = \widehat{\beta_0} + \widehat{\beta_1}\bar{x}$$

Sabemos o coeficiente do intercepto

$$\widehat{\beta_0} = \bar{y} - \widehat{\beta_1}\bar{x}$$

Substituindo:

$$\hat{y}(\bar{x}) = \left(\bar{y} - \widehat{\beta_1}\bar{x}\right) + \widehat{\beta_1}\bar{x}$$

Logo temos que o valor predito para $\bar{x}$ é igual a $\bar{y}$

$$\hat{y}(\bar{x}) = \bar{y}$$

$$\hat{y}(\bar{x}) = \bar{y} \Rightarrow \text{a reta passa por } (\bar{x}, \bar{y})$$

7. Afirma-se no texto que, no caso de regressão linear simples de Y em relação a X, a estatística R^2 (equação 3.17) é igual ao quadrado da correlação entre X e Y (equação 3.18). Prove que isso é verdade. Para simplificar, você pode assumir que $\bar{x} = \bar{y} = 0$

Temos a definição de R^2

$$R^2 = \frac{SSR}{SST}$$

$$SSR = \sum_{i=1}^{n} \widehat{y_i^2}, \quad SST = \sum_{i=1}^{n} y_i^2$$

Como $\bar{x} = \bar{y} = 0$:

$$\hat{y}_i = \widehat{\beta_1} x_i$$

$$\widehat{\beta_1} = \frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}$$

Substituindo em SSR

$$SSR = \sum_{i=1}^{n} \left(\widehat{\beta_1} x_i\right)^2$$

$$SSR = \widehat{\beta_1^2} \sum_{i=1}^{n} x_i^2$$

Subistuindo em $\widehat{\beta_1}$

$$SSR = \left(\frac{\sum_{i=1}^{n} x_i y_i}{\sum_{i=1}^{n} x_i^2}\right)^2 \sum_{i=1}^{n} x_i^2$$

$$SSR = \frac{\left(\sum_{i=1}^{n} x_i y_i\right)^2}{\sum_{i=1}^{n} x_i^2}$$

Calculando R^2

$$R^2 = \frac{SSR}{SST} = \frac{\left(\sum_{i=1}^{n} x_i y_i\right)^2}{\sum_{i=1}^{n} x_i^2 \cdot \sum_{i=1}^{n} y_i^2}$$

Definição de Correlação

$$\mathrm{cor}(X,Y) = \frac{\sum_{i=1}^{n} x_i y_i}{\sqrt{\sum_{i=1}^{n} x_i^2 \cdot \sum_{i=1}^{n} y_i^2}}$$

$$\left(\mathrm{cor}(X,Y)\right)^2 = \frac{\left(\sum_{i=1}^{n} x_i y_i\right)^2}{\sum_{i=1}^{n} x_i^2 \cdot \sum_{i=1}^{n} y_i^2}$$

Então temos que $R^2 = \left(\mathrm{cor}(X,Y)\right)^2$